

USO DE VISÃO COMPUTACIONAL EM IMAGENS DE DRONES PARA AGRICULTURA DE PRECISÃO

JOÃO OTAVIO NASCIMENTO FIRIGATO



INTRODUÇÃO

- Visão computacional é uma subárea da inteligência artificial que busca replicar funções condicionadas pela visão humana a uma máquina.
- A visão computacional tem por objetivo analisar e extrair informações de imagens.

Artificial Intelligence

A programme, which can sense, think, act and adapt

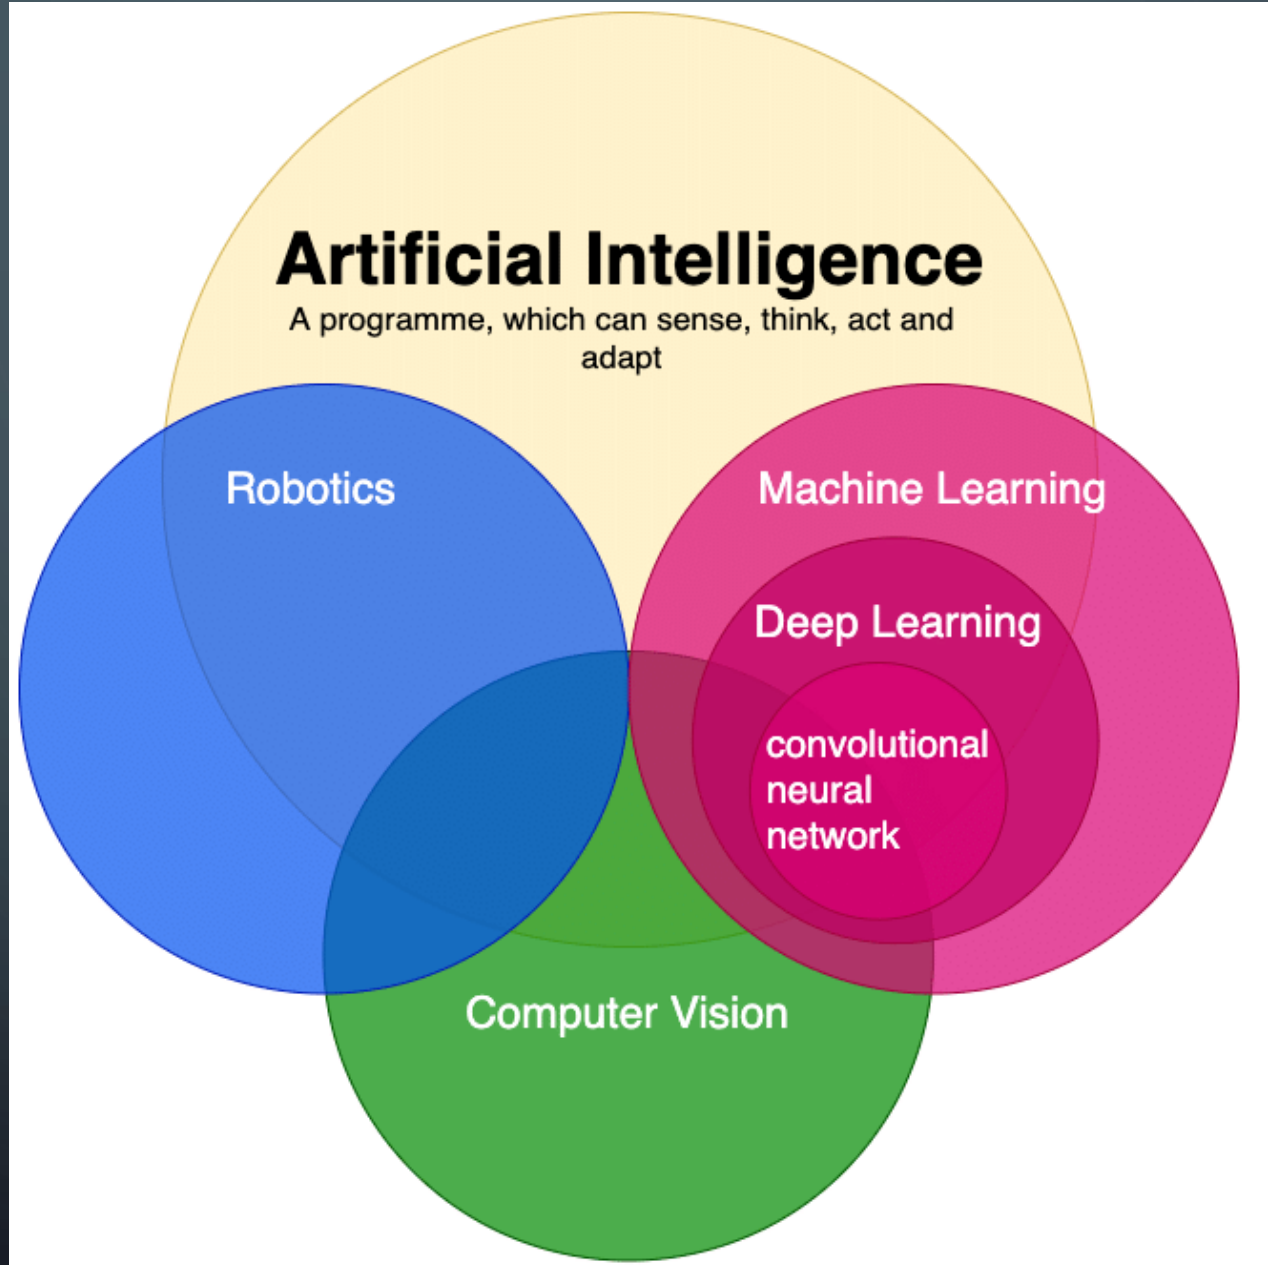
Robotics

Machine Learning

Deep Learning

convolutional
neural
network

Computer Vision



DRONES E VISÃO COMPUTACIONAL NA AGRICULTURA

- O uso de drones para obter imagens de alta resolução de cultivos agrícolas tornou possível um avanço na agricultura de precisão.
- A análise passou do nível de campo, ao nível da planta e até ao nível da folha.
- Agora temos milhões de pixels em uma imagem de Drone, possibilitando alimentar algoritmos de Visão Computacional para analisar a imagem e extrair uma enorme quantidade de informações.



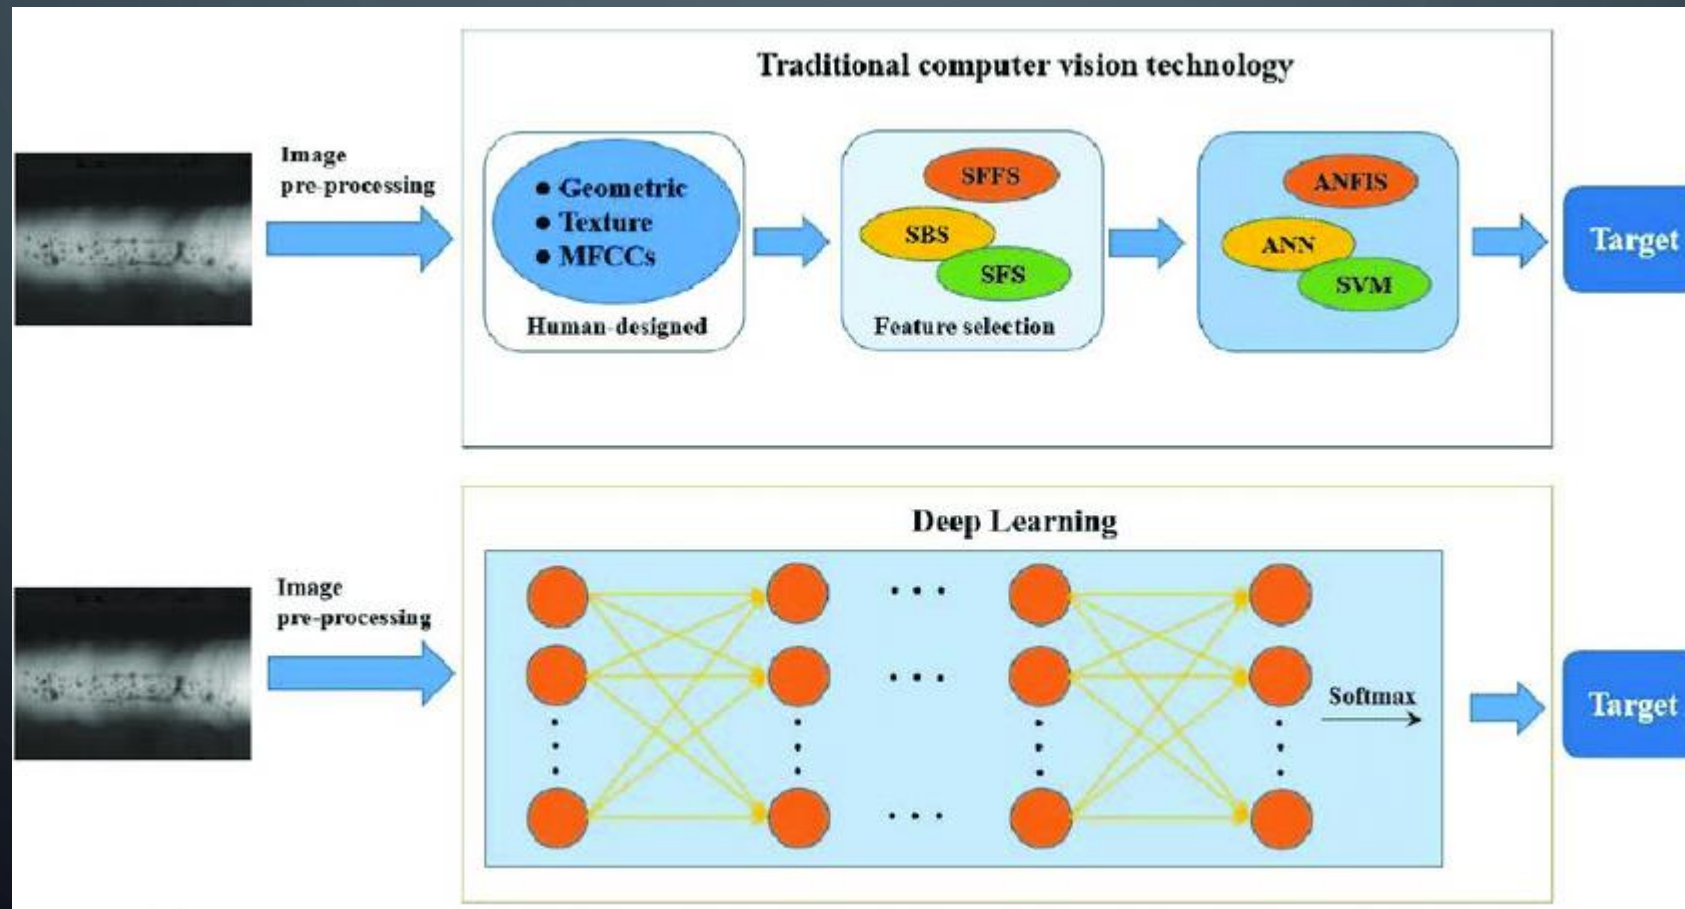
IMAGEAMENTO POR DRONE

- Escolha do tipo de Drone (asa fixa x Multi-rotor)
- Definição do GSD
- Criação do Ortomosaico e dos Índices espectrais (NDVI, SAVI, NDRE)
- Georreferenciamento

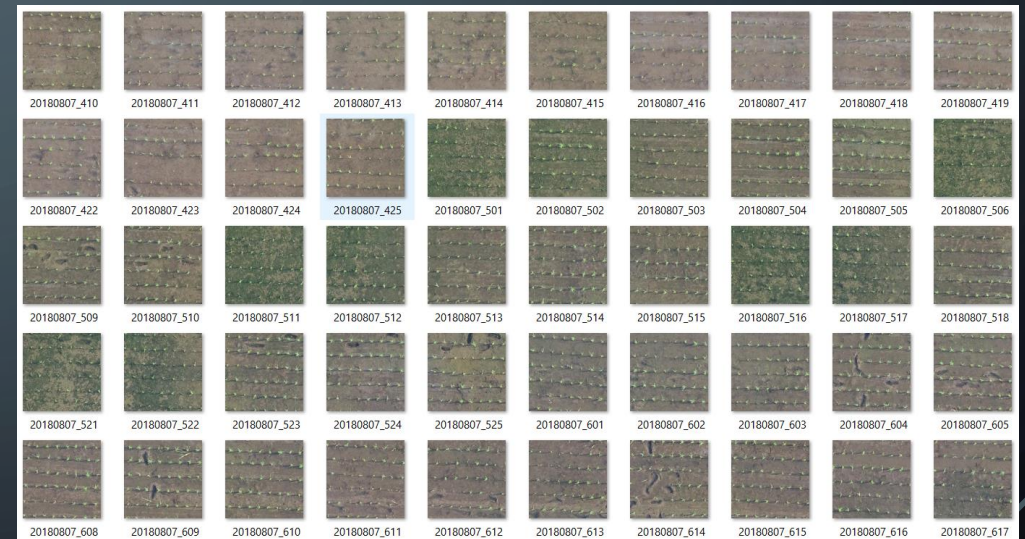

TIPOS DE SENSORES

- RGB
- Multiespectral
- Térmico

ALGORITMOS VISÃO COMPUTACIONAL TRADICIONAL X DEEP LEARNING



PREPARAÇÃO DOS DADOS PARA TAREFAS DE DEEP LEARNING




VISÃO COMPUTACIONAL TRADICIONAL

- Filtros Convolucionais
- Operações Morfológicas
- Segmentação (Limiar, Baseada em regiões, Baseada em clusters)
- Gradiente, HOG, Laplaciano
- Canny edge, Harris Corner, Hough Lines, CHT.
- Matriz GLCM
- Machine Learning


SEGMENTAÇÃO DE VEGETAÇÃO PARA CALCULO DE ÁREA FOLIAR



```
R = IMG[:, :, 0]  
G = IMG[:, :, 1]  
B = IMG[:, :, 2]  
TWOGR = 2 * G - (R+B)
```





```
THRESH = THRESHOLD_OTSU(TWOG_R)  
BINARY = TWOG_R > THRESH
```




SEGMENTAÇÃO NÃO SUPERVISIONADA (KMEANS)




KMEANS
(k=2)



CONTAGEM E IDENTIFICAÇÃO DE ARVORES



```
GRAY = CV2.CVT_COLOR(IMG, CV2.COLOR_BGR2GRAY)
RET, THRESH = CV2.THRESHOLD(GRAY, 0, 255, CV2.THRESH_BINARY_INV + CV2.THRESH_OTSU)
```





```
KERNEL = NP.ONES((3,3),NP.UINT8)
```


```
EROSION = CV2.ERODE(THRESH,KERNEL,ITERATIONS = 4)
```

```
OPENING = CV2.MORPHOLOGYEX(THRESH,CV2.MORPH_OPEN,KERNEL, ITERATIONS = 3)
```

```
SURE_BG = CV2.DILATE(OPENING,KERNEL,ITERATIONS=1)
```




```
LABEL_IMAGE = LABEL(SURE_BG)
FOR REGION IN REGIONPROPS(LABEL_IMAGE):
    Y0, X0 = REGION.CENTROID
    PRINT(Y0, X0)
    XS, YS = RASTERIO.TRANSFORM.XY(SRC.TRANSFORM, Y0, X0)
```



PRÓS X CONTRAS

Desafios:

- Baixa eficiência em problemas complexos
- Configuração de parâmetros dos algoritmos

PRÓS X CONTRAS


Benefícios:

- Boa eficiência para problemas mais simples
- Não necessita de horas de treinamento (algoritmos não supervisionados)
- Rápidos de ser implementados


VISÃO COMPUTACIONAL DEEP LEARNING

- Classificação de Imagens
- Segmentação semântica
- Segmentação de instâncias
- Detecção de Objetos

SEGMENTAÇÃO DE CANA DE AÇUCAR

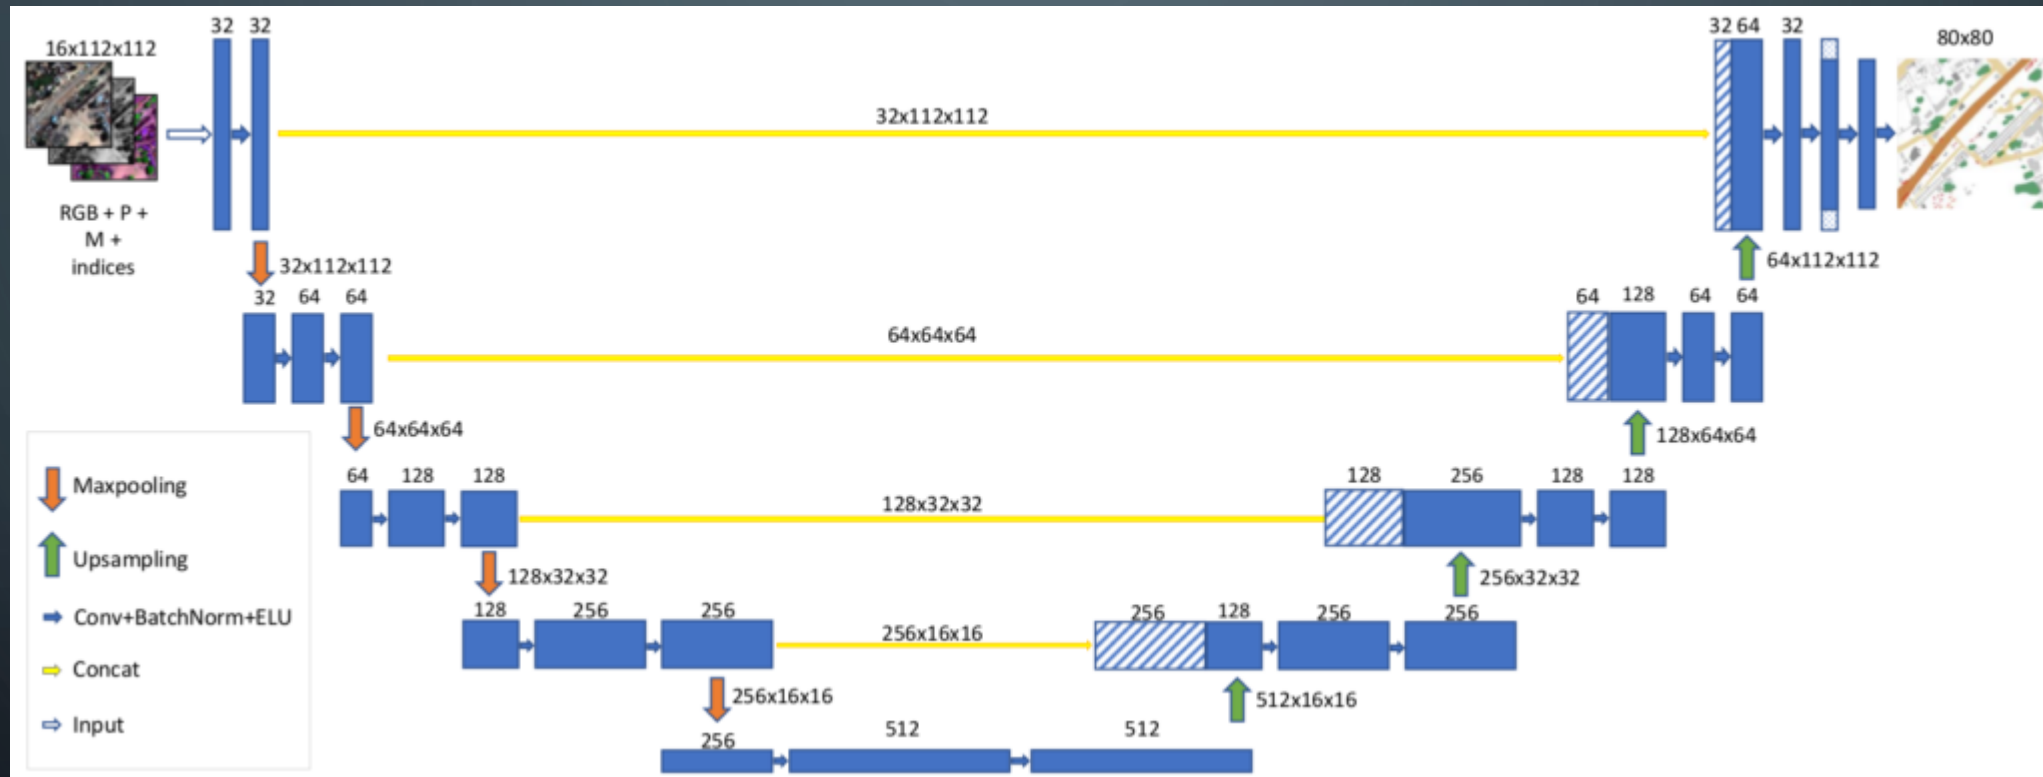


SEGMENTAÇÃO DA CANA E DE DANINHAS



<https://medium.com/@awangenh/mapping-weeds-and-crops-in-precision-agriculture-with-convolutional-neural-networks-138dab87ba00>

MODELO DE SEGMENTAÇÃO SEMÂNTICA - UNET



<https://arxiv.org/abs/1505.04597>

CONTAGEM DE PLANTAS



YOLOX

Exceeding YOLO series in 2021


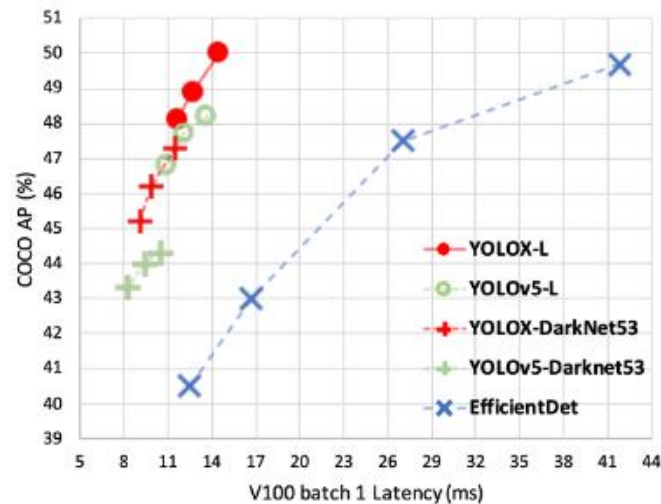



Figure 1: Speed-accuracy trade-off of accurate models (top) and Size-accuracy curve of lite models on mobile devices (bottom) for YOLOX and other state-of-the-art object detectors.

RESULTADOS



MAPEAMENTO DE PONTOS



ANÁLISE A NÍVEL DE PLANTA



SPACE  AG

PRÓS X CONTRAS

Desafios:

- Grande quantidade de dados para treinar o algoritmo
- Tempo para coleta dos dados de referência
- Hardware específico para o processamento

PRÓS X CONTRAS

Benefícios:

- Alta eficácia comparada aos algoritmos tradicionais
- Uso persistente do modelo
- Processo de aprendizado contínuo

CONCLUSÃO

- Sensibilidade do Analista para escolher qual workflow e algoritmos utilizar
- Enorme quantidade de dados gerados como resultado.
- Melhoria da monitoramento agrícola maximizando a produção.